

TÔN ĐỨC THẮNG UNIVERSITY · FACULTY OF INFORMATION TECHNOLOGY

COMPUTER VISION – FINAL REPORT

ViGround-Contrast

Low-Resource Vietnamese Referring Expression Grounding

Advisor: Ph.D. Pham Van Huy

Võ Xuân Quang – 523H0173

Hoàng Xuân Thành – 523H0178

NỘI DUNG TRÌNH BÀY

01 Bối cảnh & Vấn đề nghiên cứu

02 Tổng quan tài liệu (Related Work)

03 Phương pháp & Quy trình

04 Dữ liệu & Thiết kế Benchmark

05 Kết quả thực nghiệm

06 Thảo luận & Hạn chế

07 Kết luận & Hướng phát triển

Visual Grounding là gì?



Visual Grounding

Ánh xạ câu hỏi ngôn ngữ tự nhiên → bounding box của vật thể trong ảnh



Vấn đề với tiếng Việt

Mô hình mạnh tiếng Anh nhưng yếu nghiêm trọng khi query bằng tiếng Việt



Câu hỏi nghiên cứu

Fine-tuning tiếng Việt có giúp ích không? Hard-pair sampling có hiệu quả hơn Random?

Related Work & Vị trí của đề tài

Referring Expression Grounding

MAttNet · TransVG · MDETR

Hạn chế:

Chủ yếu tiếng Anh (RefCOCO).
Chưa xét instance confusion
đa ngôn ngữ.

Open-Vocab Detection

Grounding DINO

Hạn chế:

Vai trò trong bài: detector-
style baseline để kiểm tra độ
bền grounding xuyên ngôn
ngữ.

Large Vision-Language Models

Qwen2.5-VL · LocateAnything-3B

Hạn chế:

Pretrained model vẫn tồn tại
Vietnamese grounding gap
đáng kể.

Điểm khác biệt của đề tài:

- (1) Benchmark song ngữ EN–VI aligned ·
- (2) Hard pairs same-category ·
- (3) So sánh Random-FT vs HardPair-FT cùng budget 4K ·
- (4) Đo wrong-instance & same-box collapse

ViGround-Contrast Framework

Câu hỏi cốt lõi

1

Fine-tuning tiếng Việt có cải thiện grounding không?

Câu hỏi chiều sâu

2

Hard-pair FT có hơn Random FT trên instance-level không?

Câu hỏi thực tế

3

Trade-off giữa VI gain và English retention là gì?

Chiến lược: LoRA adaptation · Budget cố định 4,000 samples · Base model: NVIDIA/LocateAnything-3B

Experimental Pipeline



Cấu hình huấn luyện:

Tham số	Giá trị	Tham số	Giá trị
Epochs	1	Batch size	1 (grad_acc=8)
Steps	500	Learning rate	2e-6 (cosine)
Precision	bf16	Max seq len	2048

✓ Train–benchmark leakage = 0 · Cả 2 branch dùng chính xác cùng hyperparameter · Khác biệt duy nhất: chiến lược sample dữ liệu

Thiết kế dữ liệu & Benchmark

4,000

Samples / split

train_random & train_hardpair

2,000

Hard pairs

train_hardpair split

0.998+

Translation valid rate

Vietnamese queries

0%

Train-Benchmark leak

Kiểm soát chặt

Hard-Pair Mining

- Cùng image_id và category
- Khác ann_id và bounding box
- Query tương tự nhưng attribute khác nhau
- Giới hạn số pairs per image

Random Control – Fair Matching

- Matched theo category distribution
- Matched theo sentence length
- Matched theo bounding box area
- Matched theo spatial rate

Cách đánh giá Grounding DINO & Qwen2.5-VL-3B

Grounding DINO

- **Phương pháp xử lý output:**

Chọn proposal có confidence cao nhất sau khi áp ngưỡng cố định (box threshold + text threshold).

- **Đánh giá:**

Zero-shot trên cùng ảnh, query, ground-truth box và IoU implementation như LocateAnything-3B.

Qwen2.5-VL-3B

- **Phương pháp xử lý output:**


Model sinh bounding box dạng pixel coordinates. Kết quả được convert về coordinate system chung trước khi tính IoU.

- **Đánh giá:**

Zero-shot, cùng ảnh, query, ground-truth box và IoU implementation. Đảm bảo so sánh fair với LocateAnything-3B.

Cả hai model đều được đánh giá zero-shot, trên cùng bộ ảnh, query, ground-truth box và cùng IoU threshold.

Standard Benchmark – Acc@0.5



EN–VI Grounding Gap

Base

16.6 pts

Random-FT

12.3 pts

HardPair-FT


11.4 pts

Gap thu hẹp do VI tăng nhẹ + EN giảm


=> Các cải thiện VI mang tính mô tả (descriptive) – chưa đạt statistical significance ($p = 0.11 \sim 0.08$, CI chứa 0)

05 KẾT QUẢ

Hard-Pair Benchmark – Vietnamese




HardPair-FT = Random-FT về Pair Accuracy
(0.564 vs 0.564, $p = 1.0$)



HardPair-FT giảm được wrong-instance (0.101→0.095) và **same-box collapse** (0.086→0.082) – thay đổi nhỏ nhưng đúng hướng thiết kế

Cross-Architecture Evaluation



DINO vs Base VI

$\Delta = -0.362$

$p < 0.0001$

Qwen vs Base VI

$\Delta = -0.085$

$p < 0.0001$

LocateAnything-3B >> Qwen >> DINO trên Vietnamese grounding

Phân tích & Diễn giải kết quả

1

Fine-tuning VI: gains descriptive, không significant

Cải thiện nhỏ (+1.5–1.6 pts Acc@0.5) nhưng CI chứa 0. Gap thu hẹp một phần do EN giảm. Không thể kết luận mạnh trong budget 4K samples.

2

HardPair-FT: không hơn RandomFT về aggregate

Pair accuracy bằng nhau (0.564 vs 0.564, $p = 1.0$). Tuy nhiên HardPair-FT cải thiện error profile: giảm wrong-instance và same-box collapse.

3

Specialization trade-off

Adaptation không free: English Acc@0.5 giảm ~3.5 pts. Mô hình phân bổ lại capacity về phía VI distribution, không cải thiện đồng đều cả hai ngôn ngữ.

4

Training loss thấp hơn $\neq$ performance tốt hơn

HardPair-FT loss = 1.136 < Random-FT 1.223, nhưng benchmark không phản ánh điều này. Benchmark size và training budget chưa đủ để convert internal representation thành aggregate gain.

Limitations & Threats to Validity

Dữ liệu tiếng Việt từ dịch máy

Phần lớn *referring expressions VI* được dịch tự động và kiểm tra bằng *rule-based validation*. Các *spatial terms* và bản dịch bất thường được audit theo quy tắc và mẫu kiểm tra. Nhưng benchmark chưa được xác minh đầy đủ bởi **human annotators**. **Translation noise** có thể ảnh hưởng đến ước tính performance tiếng Việt.

Statistical Power & Benchmark Size

Hard-pair benchmark gồm **500 pairs** – đủ để thấy descriptive trends nhưng có thể không đủ để **detect modest improvements** với **high confidence**. Absence of **significance** $\neq$ **evidence** of no effect.

Model Specificity

Mọi kết luận gắn liền với **LocateAnything-3B** dưới cấu hình LoRA cụ thể này. *Không thể generalize* trực tiếp sang các **grounding architectures** khác.

Kết luận từ thực nghiệm

- ✓ Fine-tuning VI (cả Random và HardPair) cải thiện descriptively VI grounding, dù chưa đạt statistical significance trong budget 4K.
- ✓ HardPair-FT không hơn Random-FT về aggregate pair accuracy, nhưng cải thiện error distribution theo đúng hướng thiết kế.
- ✓ Adaptation tạo ra specialization trade-off: **VI tăng, EN giảm**. Không phải universal improvement.
- ✓ **LocateAnything-3B >> Qwen >> DINO** trên Vietnamese grounding, với khoảng cách rất lớn và có ý nghĩa thống kê.

Đóng góp: Benchmark song ngữ EN–VI aligned · Hard-pair mining framework · Controlled comparison RandomFT vs HardPairFT · Evidence về VI grounding gap

Future Work

11.1

Mở rộng Benchmark & Tối ưu hóa

Tăng quy mô hard-pair benchmark · Ablation về tỉ lệ random/hard-pair
· Kéo dài optimization budget

11.2

Phân tích Failure Cases định tính

Xây dựng qualitative analysis để liên kết benchmark-level reduction với concrete prediction improvements

11.3

Pair-Aware Contrastive Training

Huấn luyện đồng thời cả 2 thành viên của mỗi hard pair · Thêm contrastive objective phạt wrong-instance selection và same-box collapse. Giải thích tại sao HardPair-FT chưa vượt Random-FT.

ViGround-Contrast: Low-Resource Vietnamese Referring Expression Grounding

Q & A

Ton Duc Thang University · Faculty of Information Technology · 2026